Работа с речевыми аудиоданными в машинном обучении

Лепендин Андрей Александрович
доцент кафедры информационной безопасности
Алтайский государственный университет

План лекции

Временное и спектральное представления аудиосигнала

- дискретизация и квантование
- Фурье-спектрограммы
- компоненты спектрограмм человеческой речи

Основные задачи обработки речи

Примеры подходов к решению задач обработки речи

- Распознавание речи (Automatic Speech Recognition)
- Распознавание дикторов (Automatic Speaker Verification)

Временное и спектральное представления аудиосигнала

Что такое звук?

Физика: «это физическое явление, представляющее собой распространение упругих волн в газообразной, жидкой или твёрдой среде»

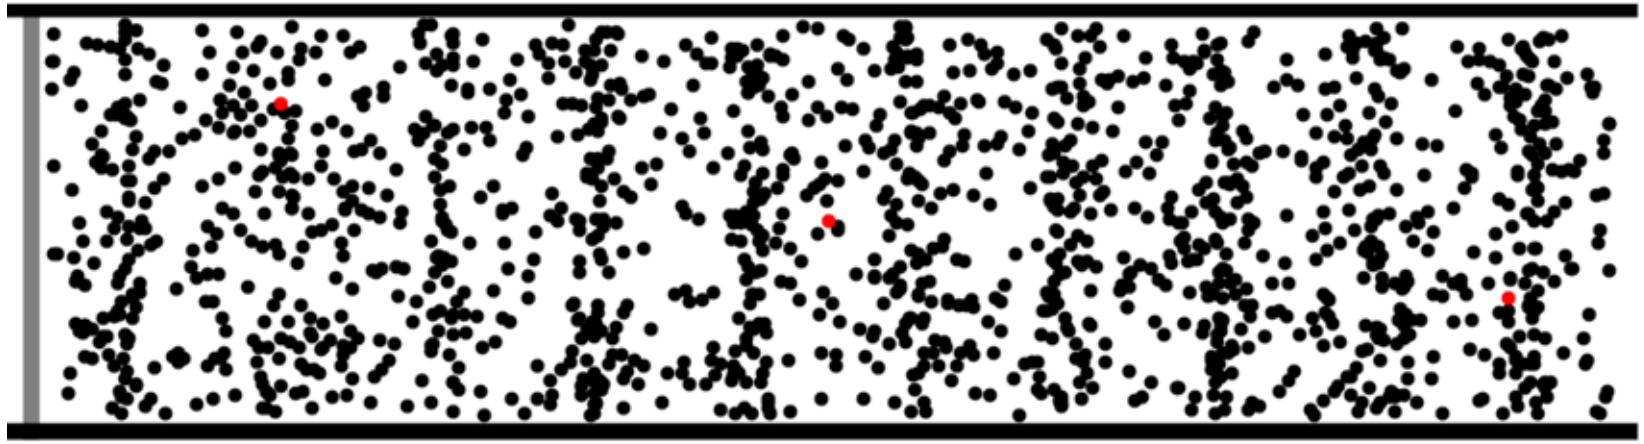

Звук в акустике – продольная волна

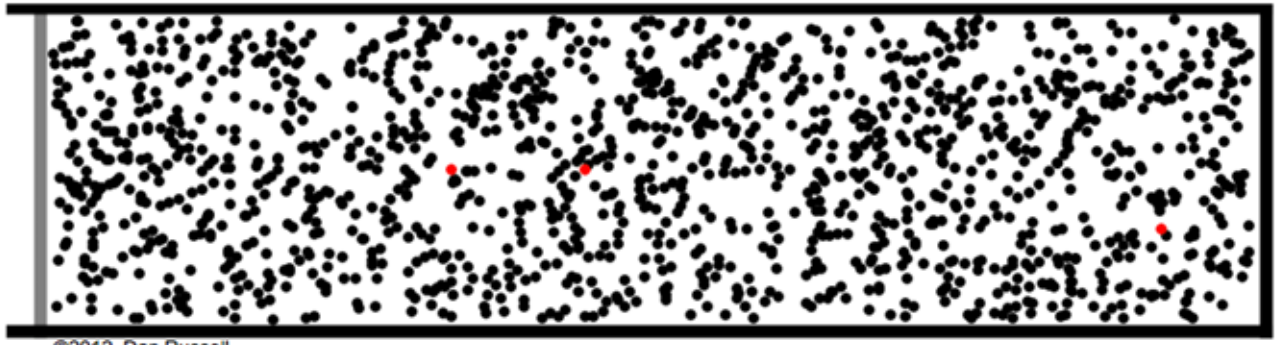

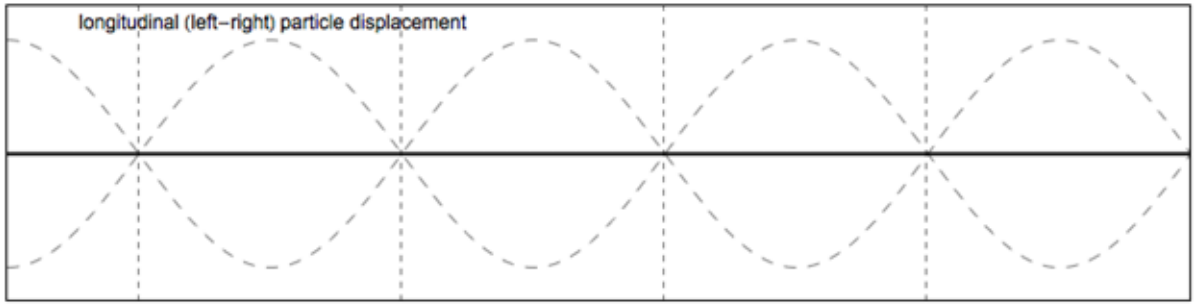

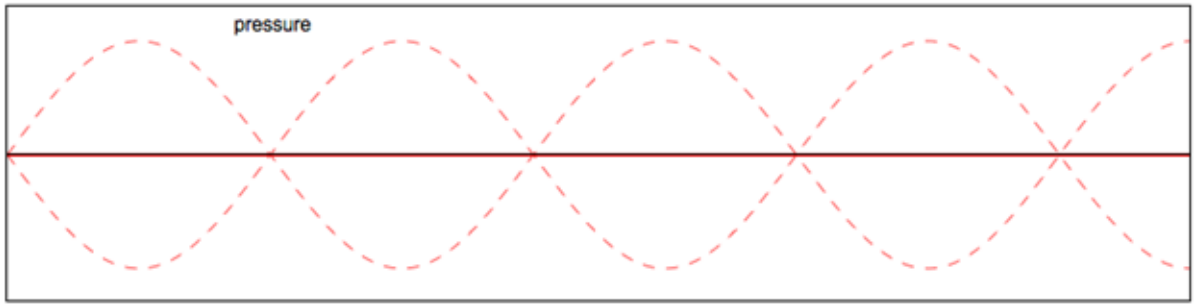

Чем улавливается звук?

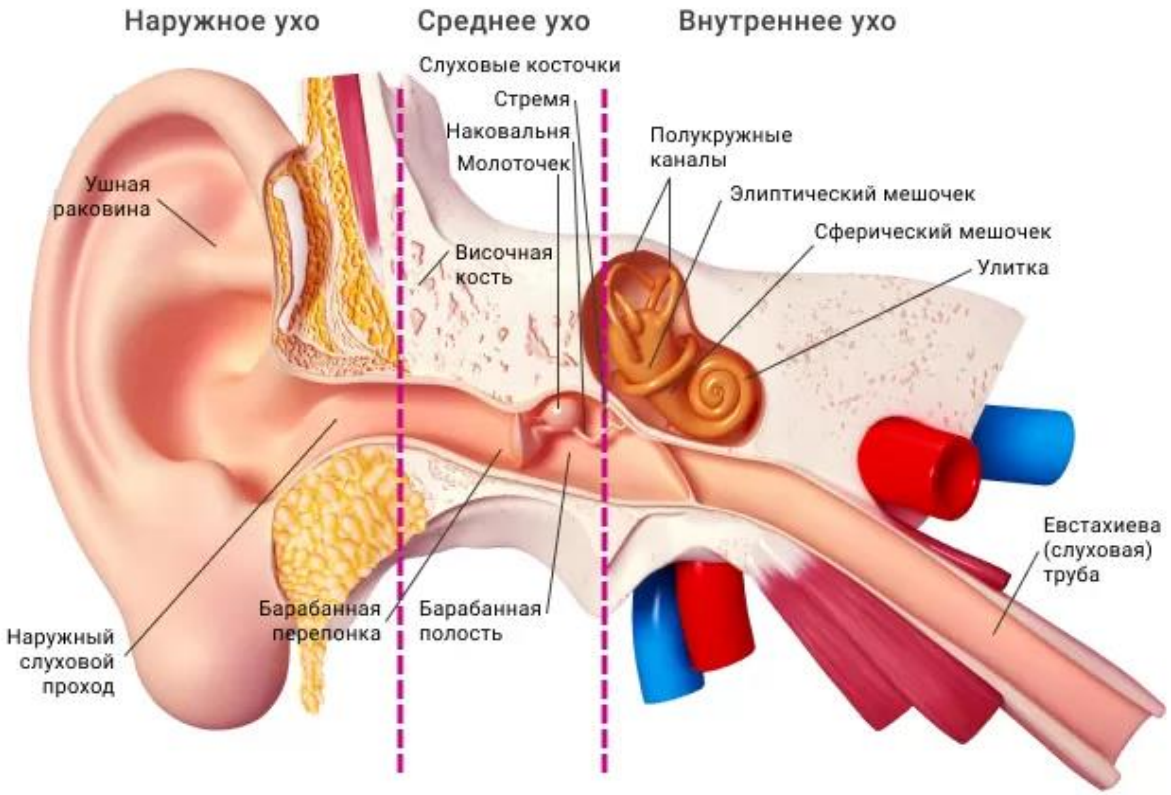

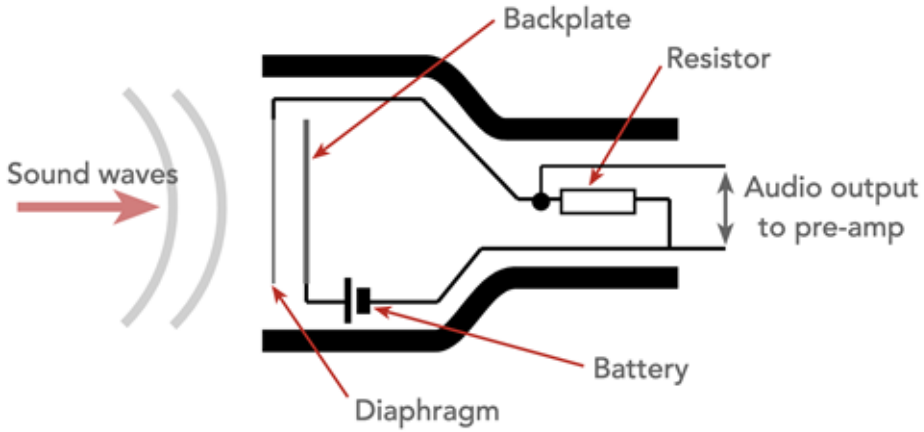

https://sluh.by/hearing-about/stroenie-organa-sluha/

https://blog.accusonus.com/science-of-sound/how-microphones-work

Как хранить звук в цифровой форме?

Аналоговый сигнал нужно

- **Дискретизировать:** представить в виде последовательности значений в дискретные моменты времени с равным шагом
- **Квантовать:** разбить диапазон значений сигнала на набор уровней и заменить значения дискретного сигнала на ближайшие значения из этого набора
- **Закодировать:** представить полученный квантованный ряд значений в наиболее компактной форме

Аналогово-цифровое преобразование

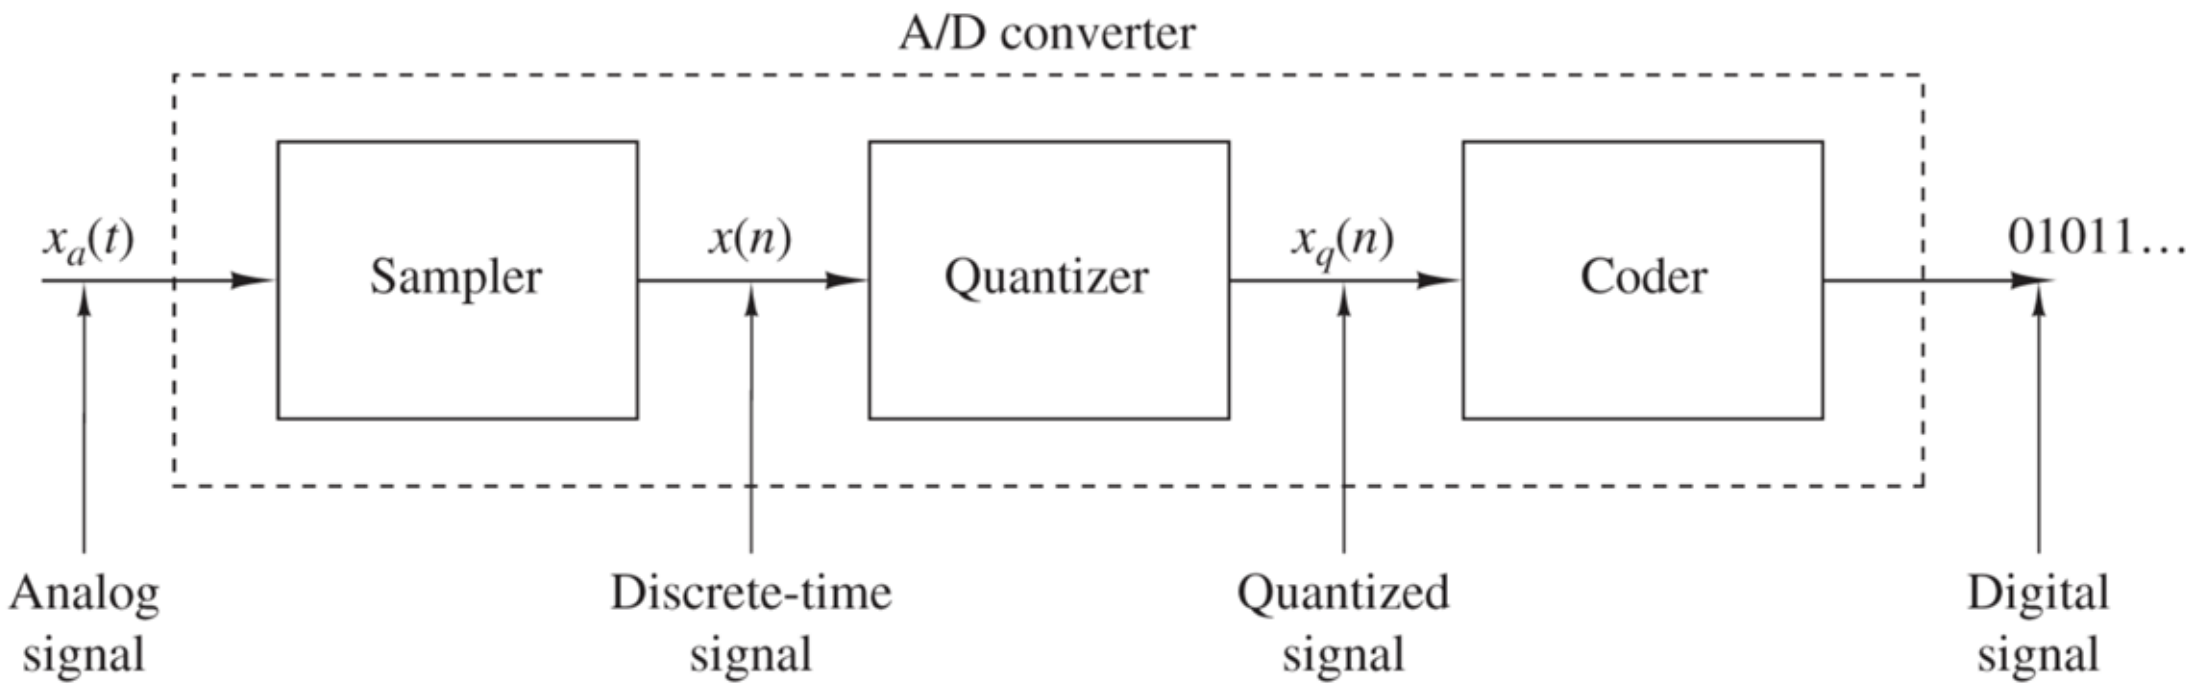

https://is.muni.cz/el/1433/jaro2012/PA190/um/Slides_02.pdf

Аналогово-цифровое преобразование

https://github.com/karpnv/speech-tech-mipt/tree/main/week04

Цифро-аналоговое преобразование

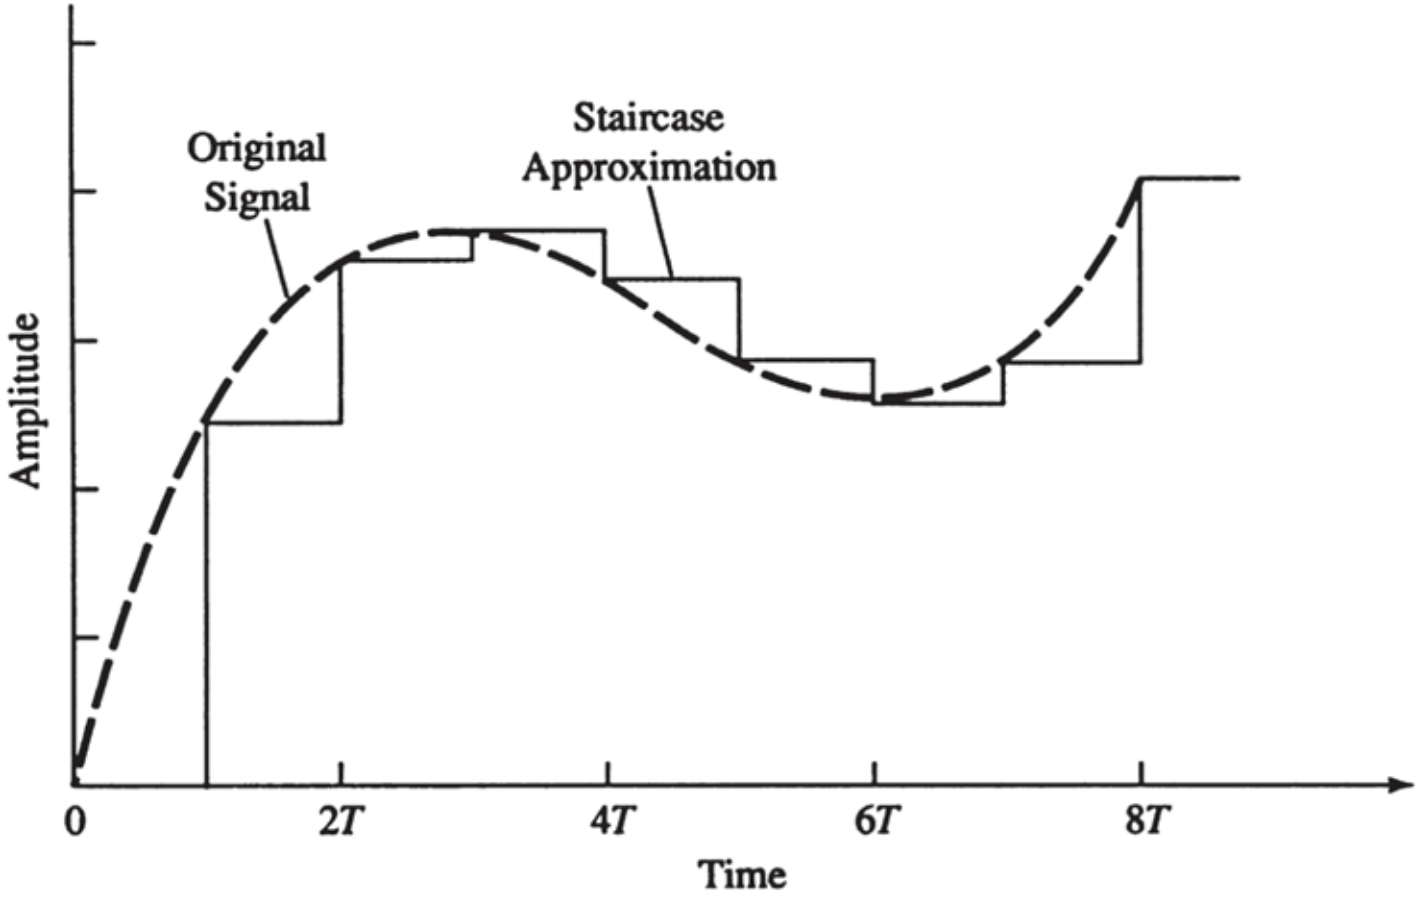

https://is.muni.cz/el/1433/jaro2012/PA190/um/Slides_02.pdf

Основные характеристики

- **Sample rate (SR)** – число отсчетов на 1 секунду (8 кГц, 22,05 кГц, 44,1 кГц, ...)
- **Sample size** – число бит на один отсчет (8, 10, 16, ...)
- **Число каналов** – сколько сигналов записывалось одновременно (моно(1), стерео(2), ...)

8000 Hz

The international G.711 standard for audio used in telephony uses a sample rate of 8000 Hz (8 kHz). This is enough for human speech to be comprehensible.

44100 Hz

The 44.1 kHz sample rate is used for compact disc (CD) audio. CDs provide uncompressed 16-bit stereo sound at 44.1 kHz. Computer audio also frequently uses this frequency by default.

48000 Hz

The audio on DVD is recorded at 48 kHz. This is also often used for computer audio.

96000 Hz

High-resolution audio.

192000 Hz

Ultra-high resolution audio. Not commonly used yet, but this will change over time.

https://developer.mozilla.org/en-US/docs/Web/Media/Formats/Audio_concepts

Другие характеристики

- **Мощность** P – квадрат значения отсчета сигнала
- **Энергия сигнала** E – сумма квадратов отсчетов (мощностей)

Часто применяют шкалу в децибелах:

$$\mathrm{SNR}_{dB} = 10 \log_{10} \frac{E_{\text{signal}}}{E_{\text{noise}}}$$

Отношение сигнал-шум

“Например, если громкость звука (субъективно определяемая его интенсивностью) возросла на 10 дБ, то это значит, что интенсивность звука возросла в 10 раз, а звуковое давление — приблизительно в 3,16 раза”

https://ru.wikipedia.org/wiki/%D0%94%D0%B5%D1%86%D0%B8%D0%B1%D0%B5%D0%BB

Пример речевого сигнала

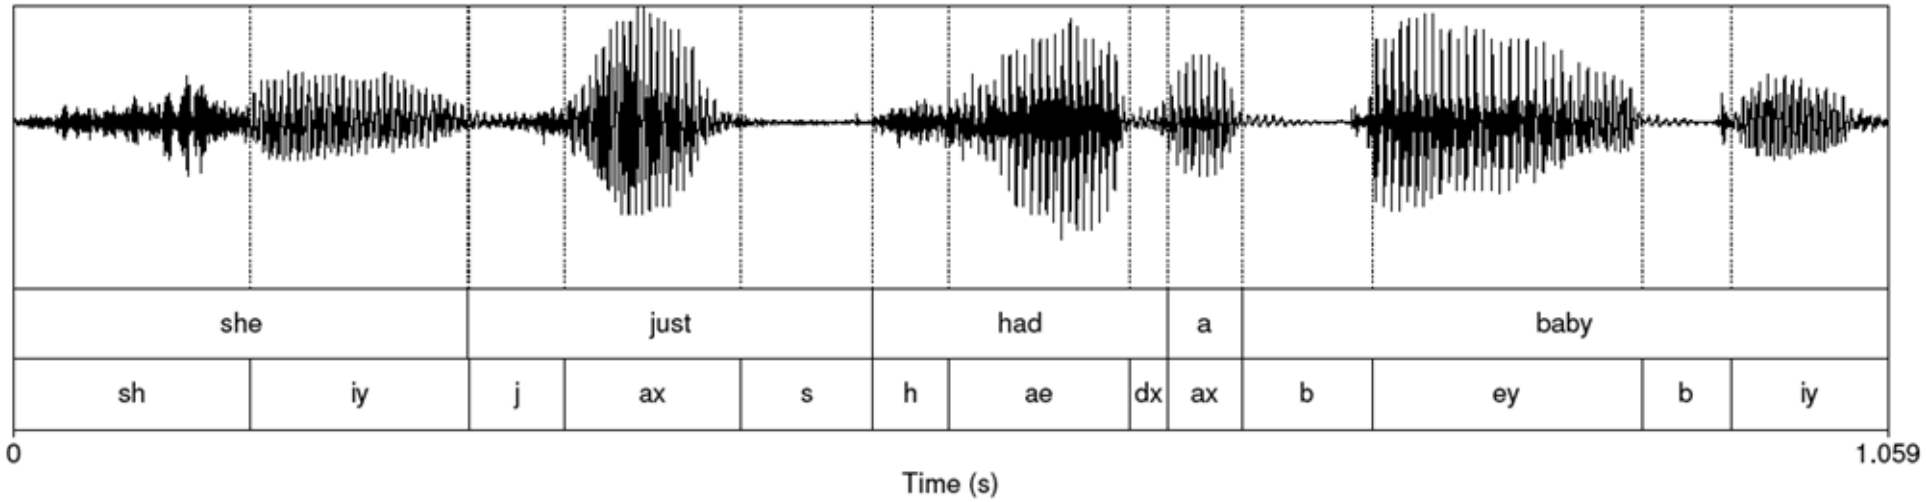

- Гласные звуки имеют регулярные амплитудные пики
- Фрикативные согласные похожи на шум ([sh])
- Взрывные (смычные) согласные – тишина, а затем резкий «взрыв» ([b])

В чем сложность работы с речью?

- Один звук состоит из 1000-4000 отсчетов, это довольно много
- Нет каких-то «инвариантов» из-за воздействия шумов и особенностей произношения
- Нужно учитывать периодичность, присутствующую в сигнале

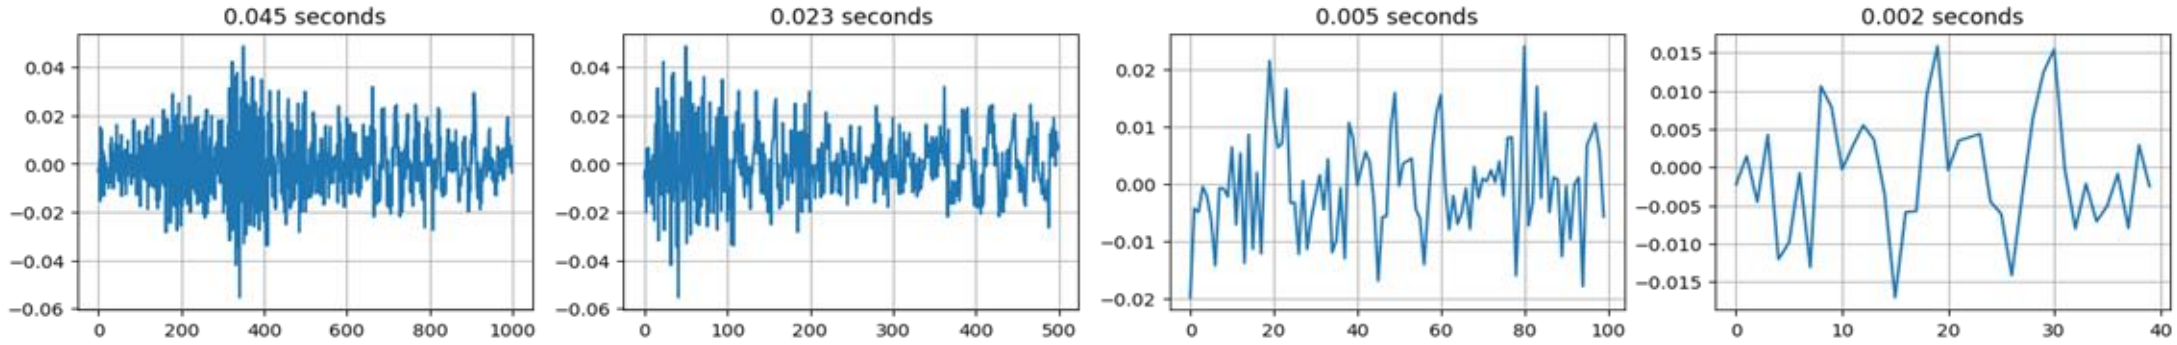

Сложная волна как сумма синусоид

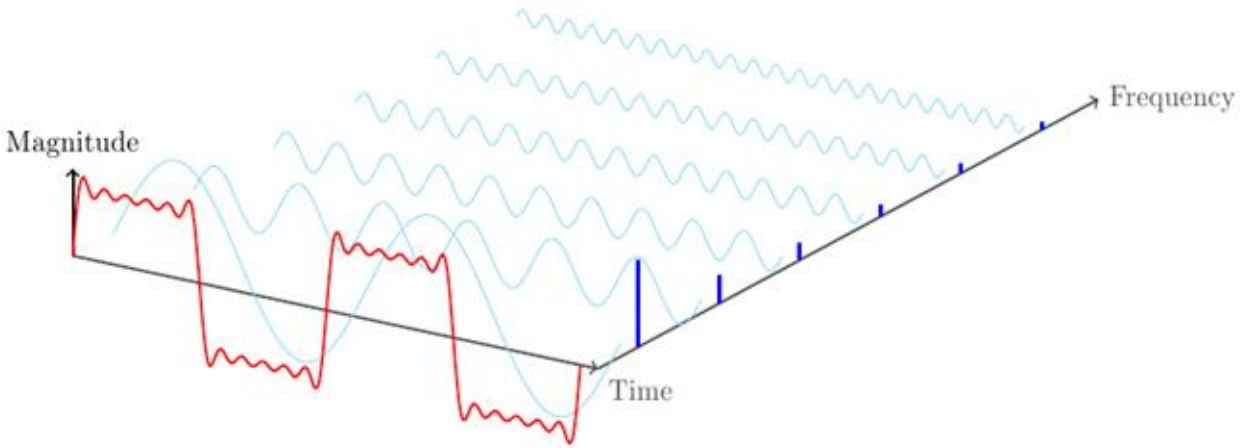

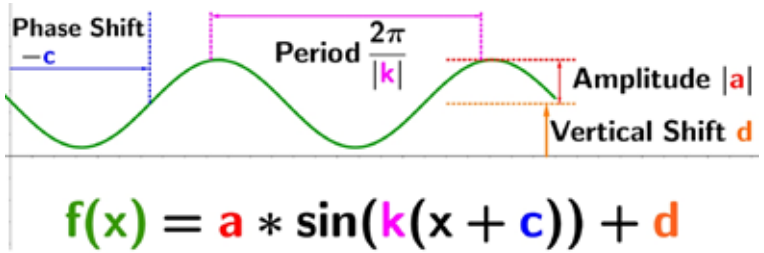

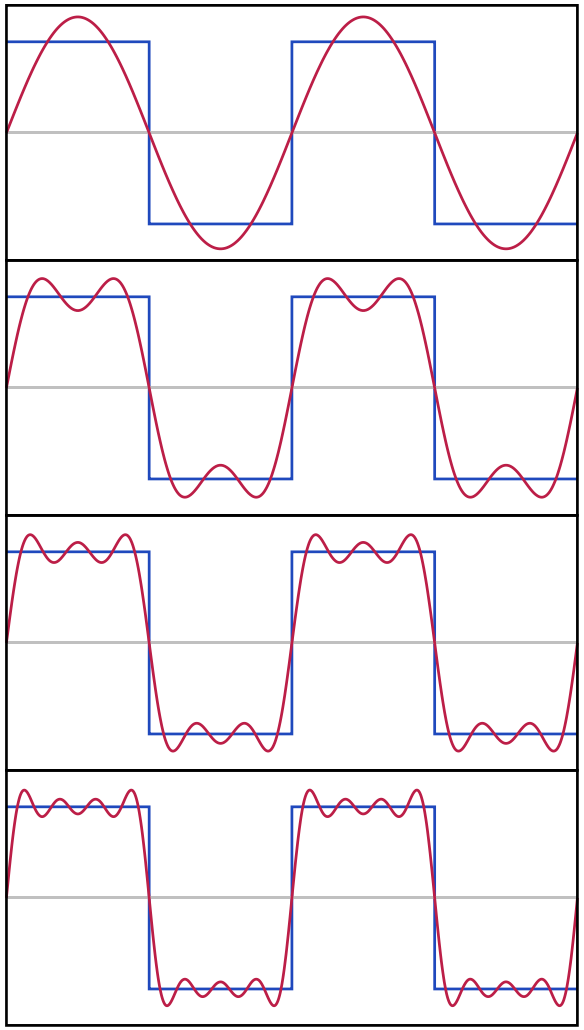

https://en.wikipedia.org/wiki/Fourier_series

Преобразование Фурье

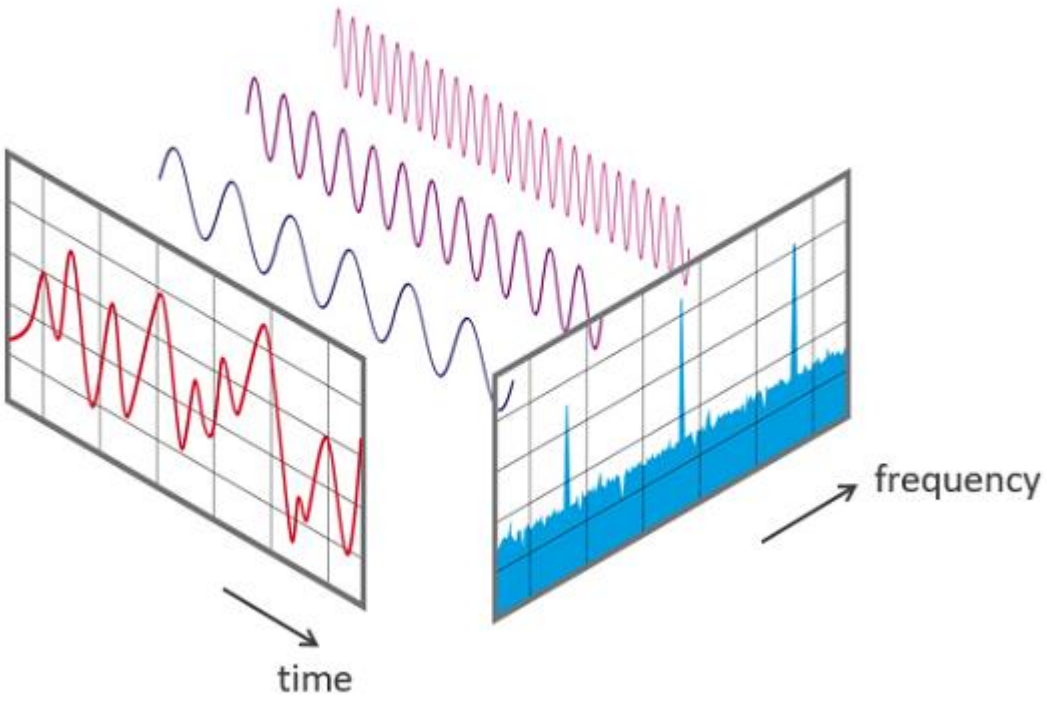

Fourier transform integral

$$\hat{f}(\xi) = \int_{-\infty}^{\infty} f(x)\, e^{-i2\pi\xi x}\, dx, \quad \forall\, \xi \in \mathbb{R}.$$

Частота

Сигнал

$$f : \mathbb{R} \to \mathbb{R}$$
$$\hat{f} : \mathbb{R} \to \mathbb{C}$$

Представляет сигнал как разложение на индивидуальные компоненты с определенными **амплитудами** и **частотами**

Сигнал f как **вещественнозначная** функция, зависящая от времени, преобразуется в **комплекснозначную** функцию, зависящую от частоты

Прямое и обратное преобразования

Fourier transform integral

$$\hat{f}(\xi) = \int_{-\infty}^{\infty} f(x)\, e^{-i2\pi\xi x}\, dx, \quad \forall\, \xi \in \mathbb{R}.$$

Fourier inversion integral

$$f(x) = \int_{-\infty}^{\infty} \hat{f}(\xi)\, e^{i2\pi\xi x}\, d\xi, \quad \forall\, x \in \mathbb{R},$$

$$= 2\int_{0}^{\infty} \mathrm{Re}\Big(\hat{f}(\xi)\cdot e^{i2\pi\xi x}\Big) d\xi$$

$$= 2\int_{0}^{\infty} \Big(\mathrm{Re}(\hat{f}(\xi))\cdot\cos(2\pi\xi x) - \mathrm{Im}(\hat{f}(\xi))\cdot\sin(2\pi\xi x)\Big)\, d\xi.$$

Свойство сопряженности

$$\hat{f}(\xi) = \begin{cases} \int_{-\infty}^{\infty} f(x)\, e^{-i2\pi\xi x}\, dx, & \xi \geq 0 \\ \hat{f}^{*}(|\xi|) & \xi < 0, \end{cases}$$

Формула Эйлера

$$e^{jx} = \cos x + j\sin x$$

$$\hat{f}(\xi_1) = c_1$$
$$\hat{f}(\xi_2) = c_2$$

$$f(x) = A_1\cos(2\pi\xi_1 x + \phi_1) + A_2\cos(2\pi\xi_2 x + \phi_2)$$
$$A_k = \sqrt{\mathrm{Re}(\mathrm{c_k})^2 + \mathrm{Im}(\mathrm{c_k})^2}$$
$$\tan\phi = \frac{C}{B}$$

$$A\ \cos(\omega t + \phi) = B\cos(\omega t) + C\sin(\omega t)$$
$$A = \sqrt{B^2 + C^2},\ \tan\phi = \frac{C}{B}$$

Пример с двумя компонентами

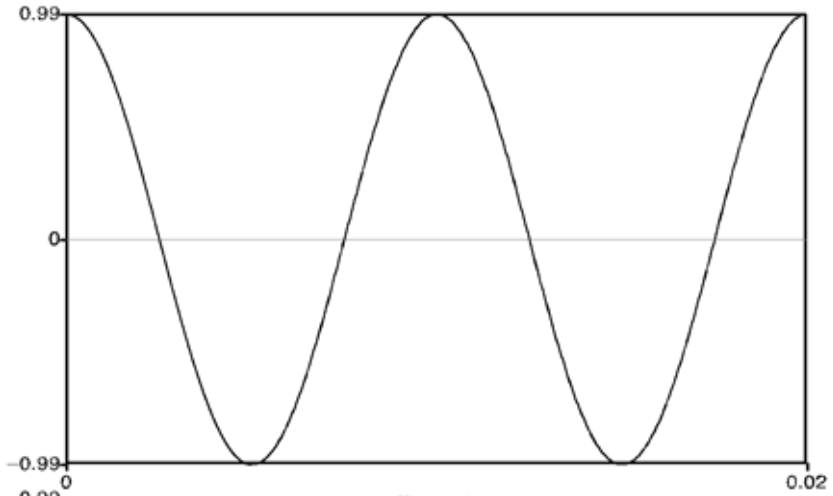

100 Гц

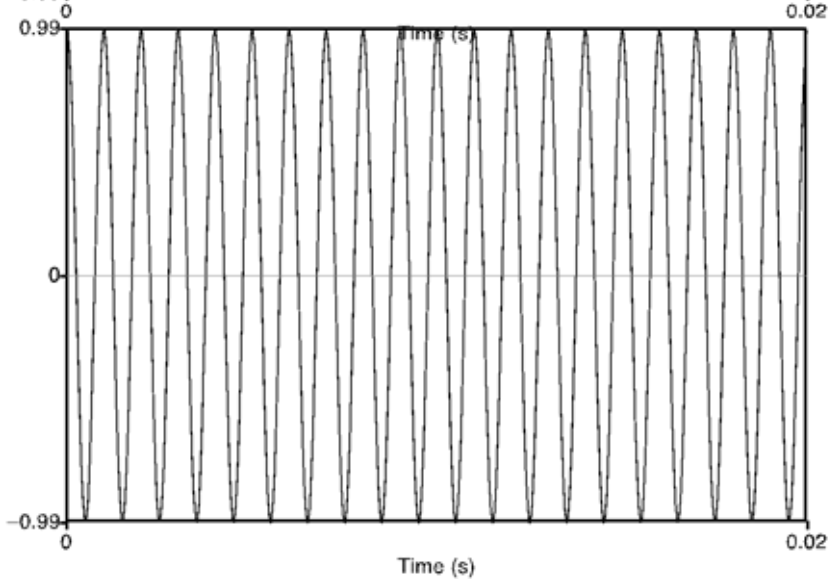

1000 Гц

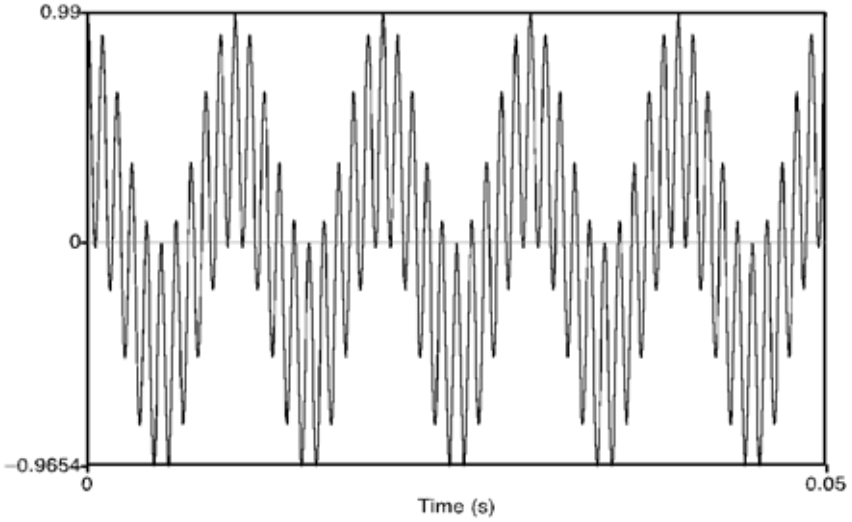

сумма

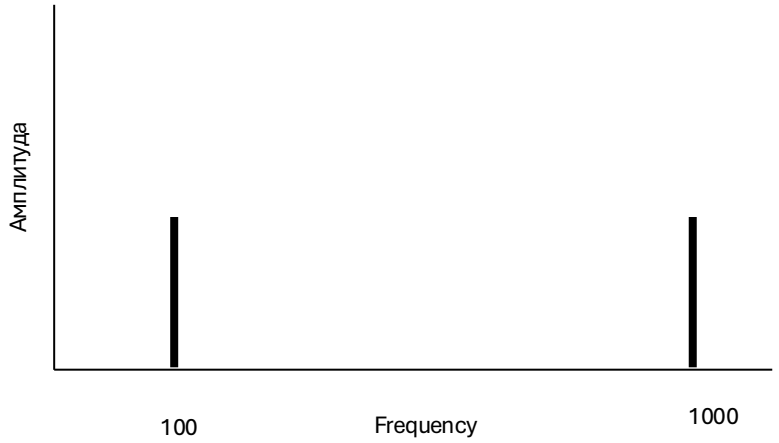

Дискретное Фурье-преобразование

$$X = \mathbf{M}x$$

$$M_{mn} = \exp\left(-2\pi i \frac{(m-1)(n-1)}{N}\right)$$

$$\mathbf{M} = \begin{pmatrix} 1 & 1 & 1 & 1 & \dots & 1 \\ 1 & e^{-\frac{2\pi i}{N}} & e^{-\frac{4\pi i}{N}} & e^{-\frac{6\pi i}{N}} & \dots & e^{-\frac{2\pi i}{N}(N-1)} \\ 1 & e^{-\frac{4\pi i}{N}} & e^{-\frac{8\pi i}{N}} & e^{-\frac{12\pi i}{N}} & \dots & e^{-\frac{2\pi i}{N}2(N-1)} \\ 1 & e^{-\frac{6\pi i}{N}} & e^{-\frac{12\pi i}{N}} & e^{-\frac{18\pi i}{N}} & \dots & e^{-\frac{2\pi i}{N}3(N-1)} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & e^{-\frac{2\pi i}{N}(N-1)} & e^{-\frac{2\pi i}{N}2(N-1)} & e^{-\frac{2\pi i}{N}3(N-1)} & \dots & e^{-\frac{2\pi i}{N}(N-1)^2} \end{pmatrix}$$

Пример дискретного преобразования

$$F = 2kHz$$
$$f(t) = 10\sin(2\pi 10t) + 3\sin(2\pi 100t)$$

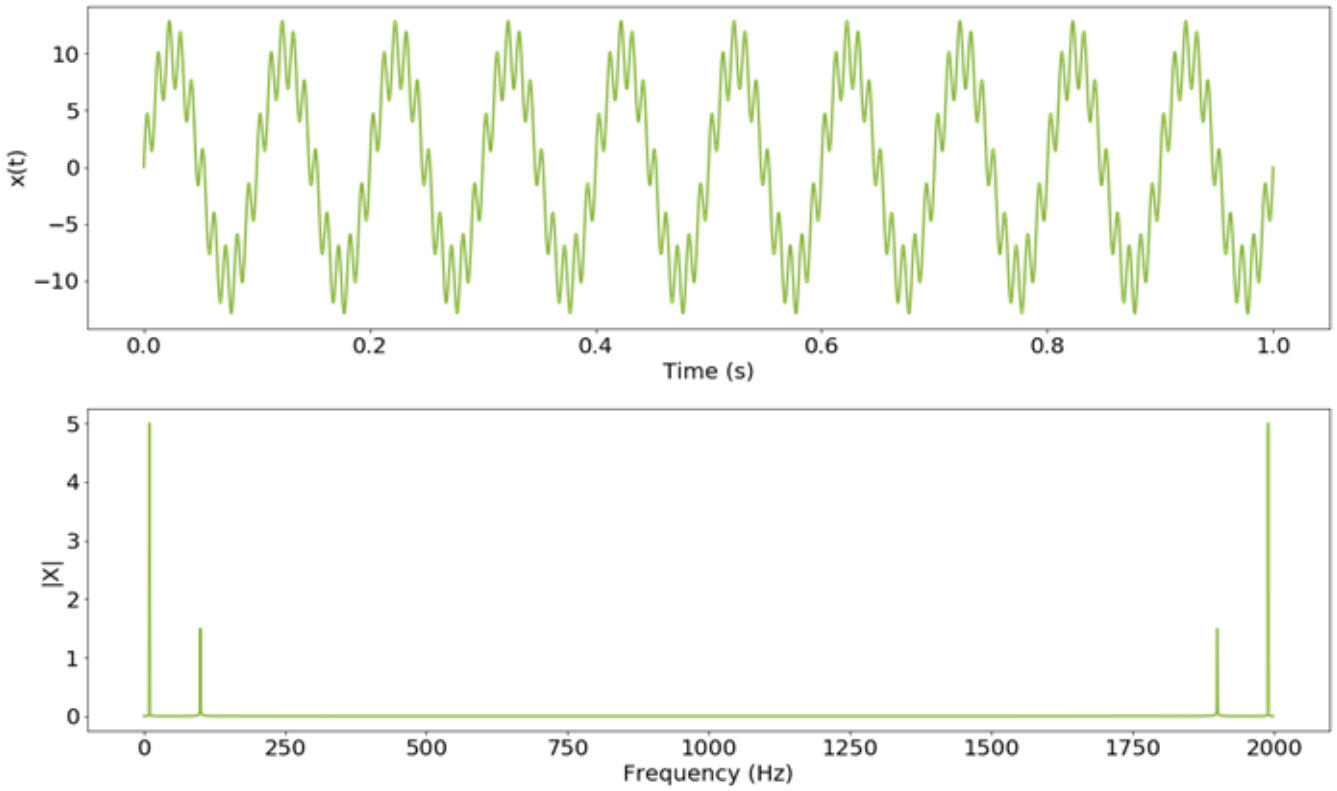

Пример дискретного преобразования

$$F = 2kHz$$
$$f(t) = 10\sin(2\pi 10t) + 3\sin(2\pi 100t)$$

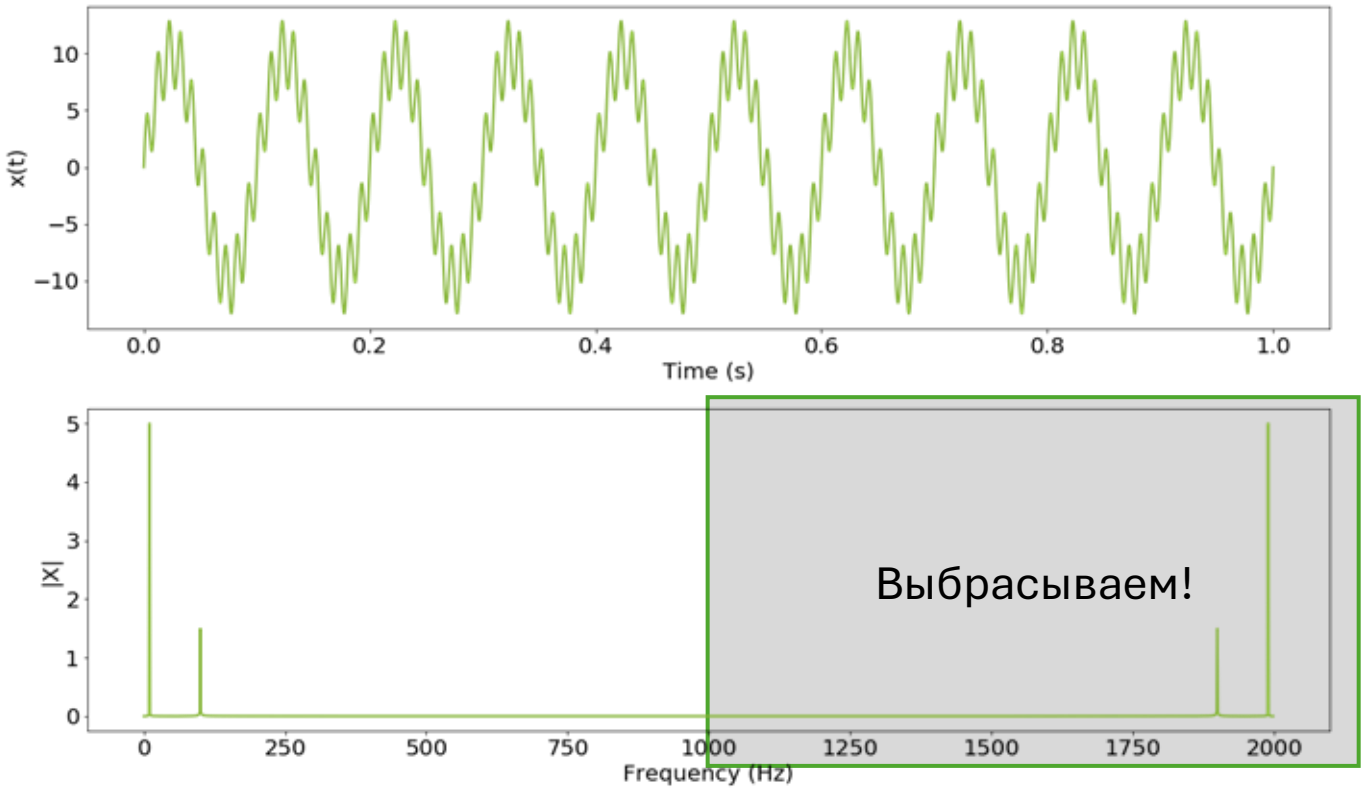

$$\begin{aligned}
X_m &= \sum_{n=0}^{N-1} x_n \exp\left(-j2\pi\frac{m}{N}n\right) \\
X_{N-m} &= \sum_{n=0}^{N-1} x_n \exp\left(-j2\pi\frac{N-m}{N}n\right) \\
&= \sum_{n=0}^{N-1} x_n \exp\left(-j2\pi n + j2\pi\frac{m}{N}n\right) \\
&= \sum_{n=0}^{N-1} x_n \exp\left(j2\pi\frac{m}{N}n\right) \\
&= (X_m)^*
\end{aligned}$$

Теорема Котельникова

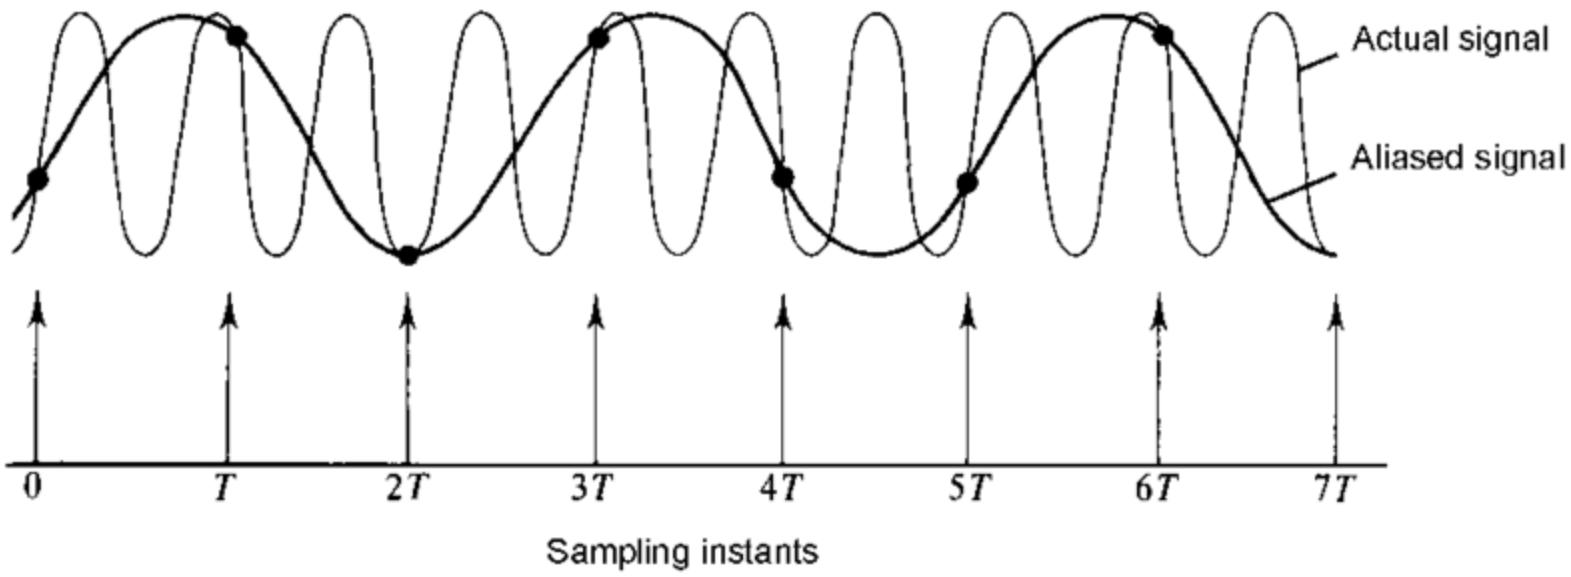

Частота дискретизации (sample rate) должна быть **по меньшей мере в два раза выше** максимальной частоты компонент сигнала

https://www.researchgate.net/figure/An-example-of-aliasing-in-the-time-domain-The-two-signals-have-the-same-values-at-the_fig6_28359715

Short-time Fourier Transform (STFT)

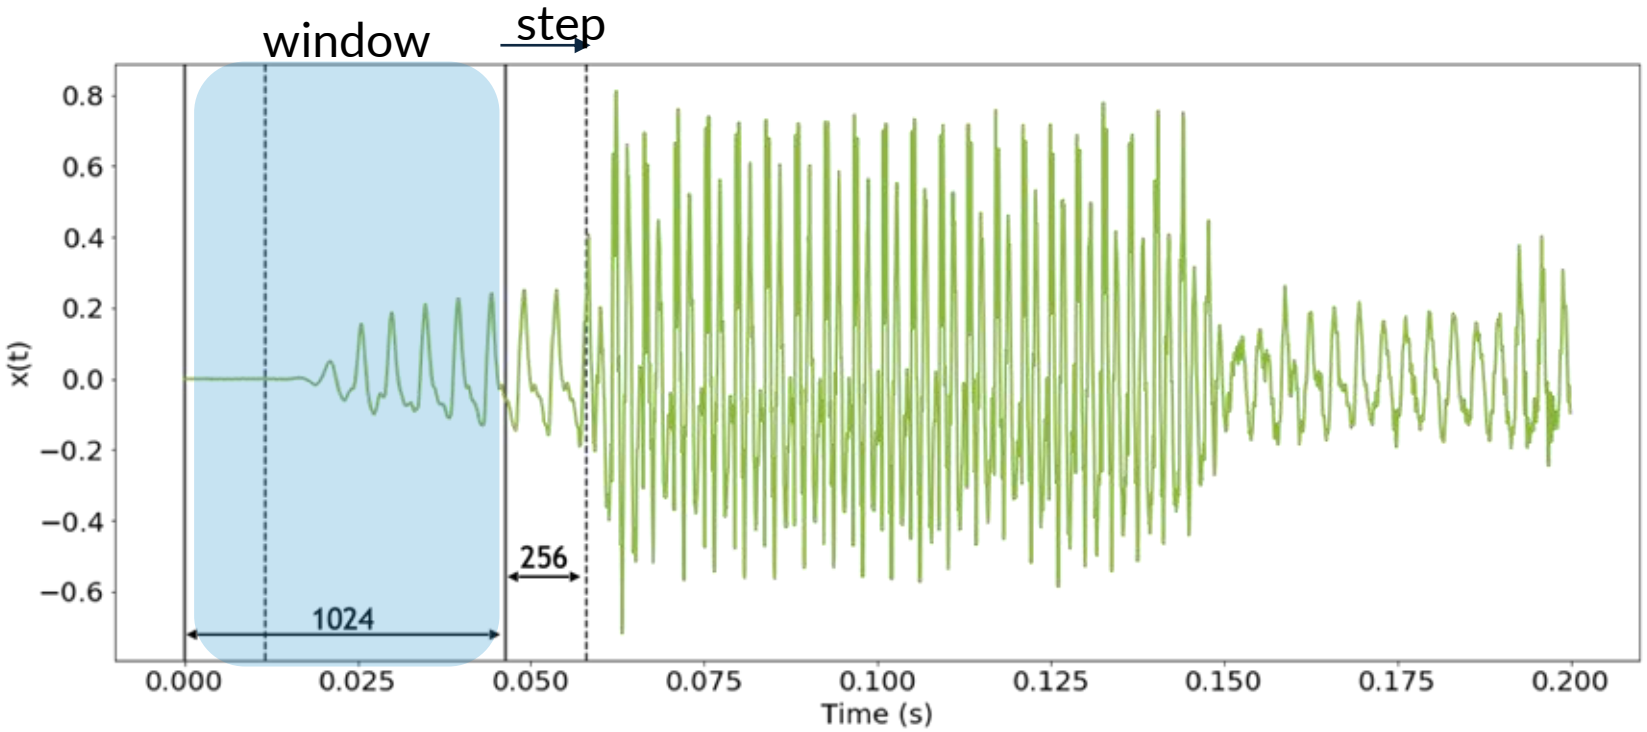

Short-time Fourier Transform (STFT)

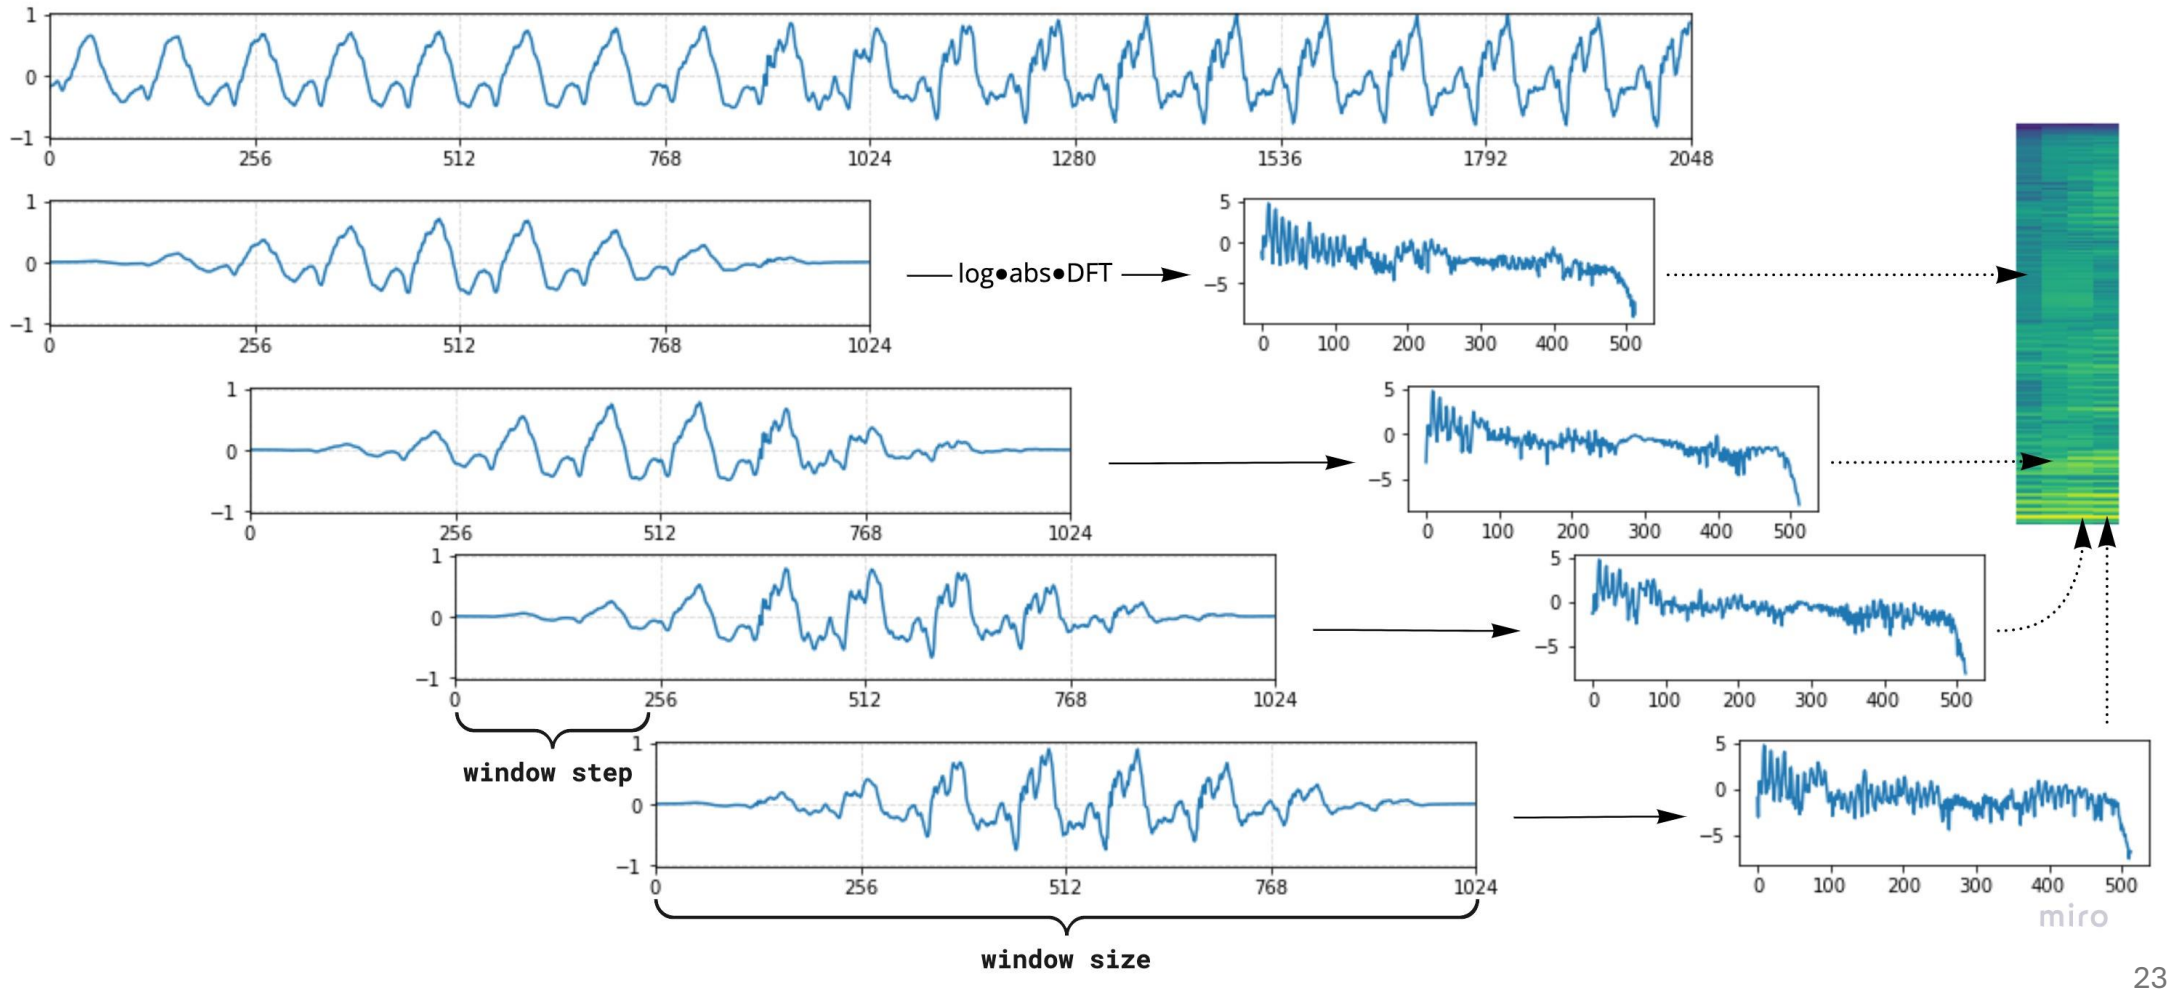

Пример спектрограммы

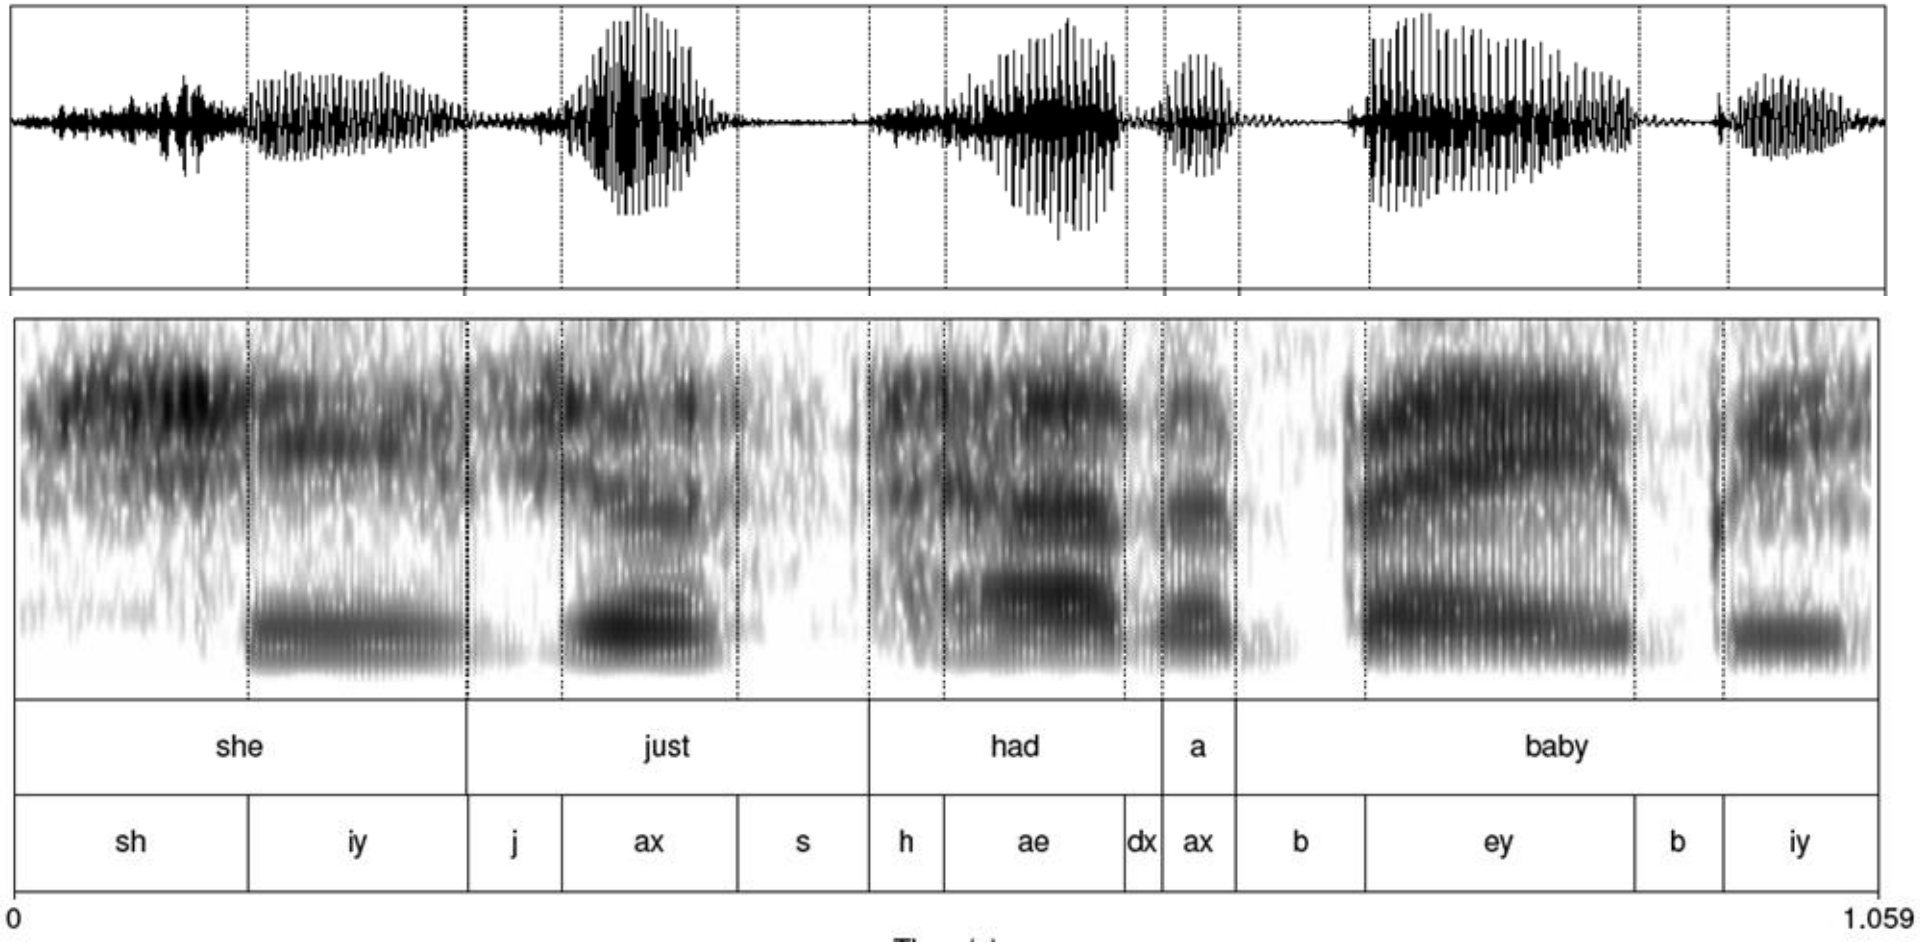

Спектрограммы отдельных фонем

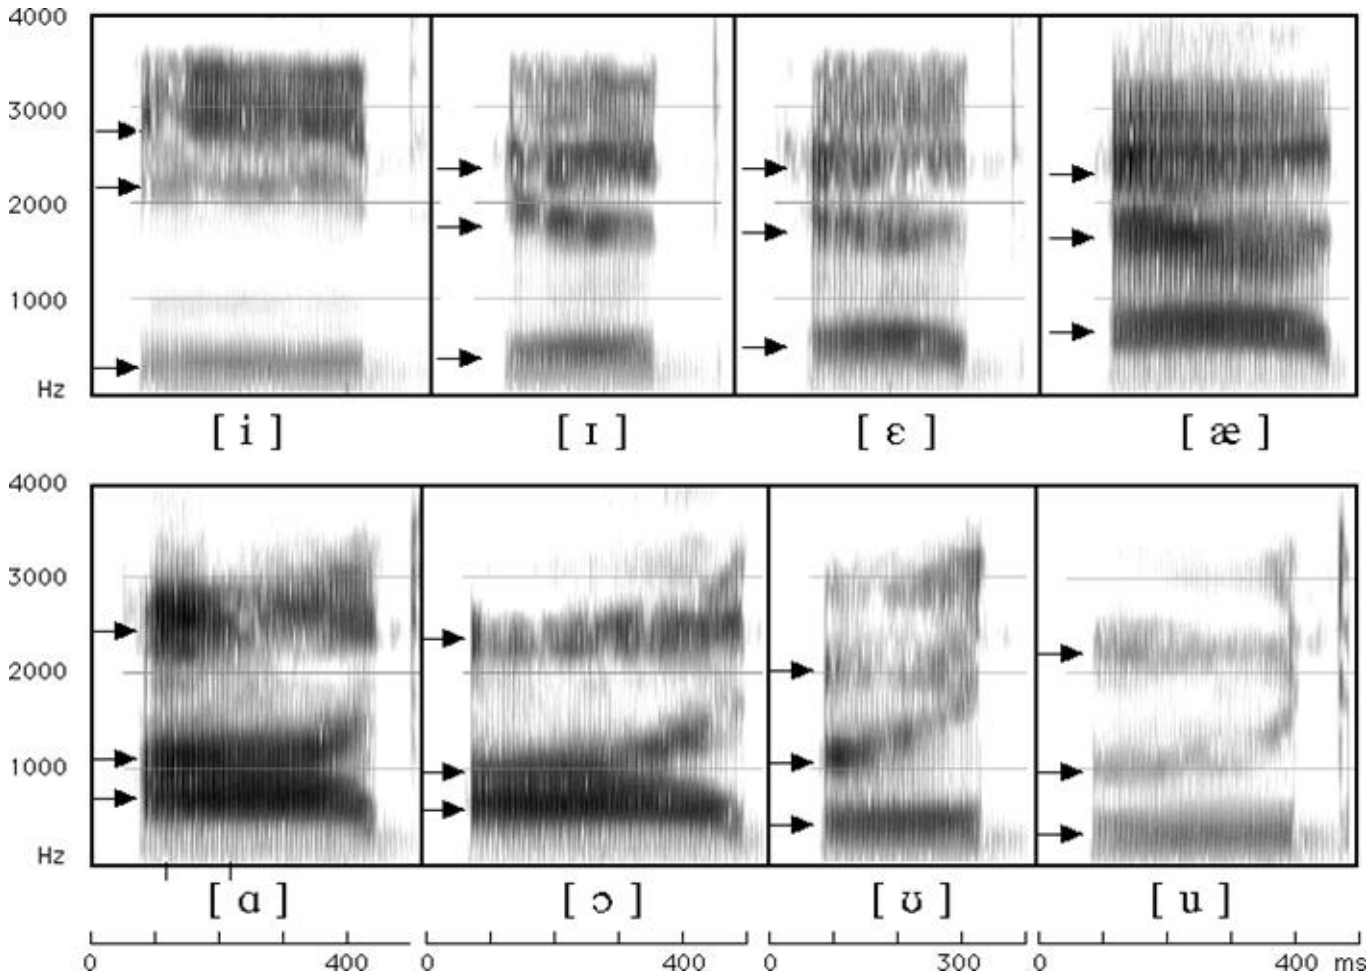

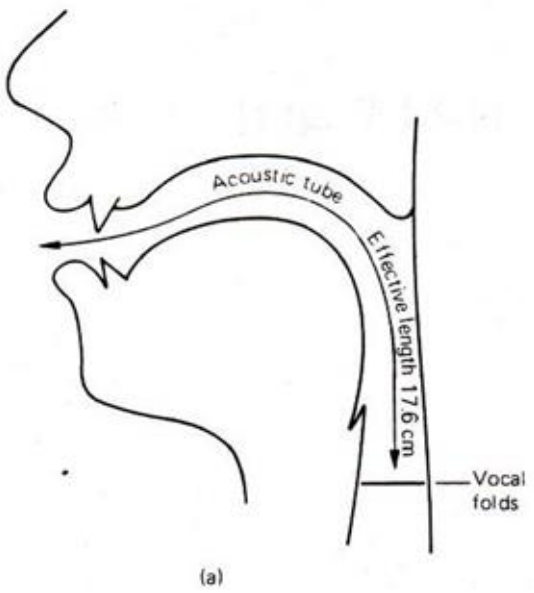

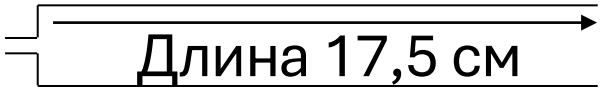

$f = c / \lambda$

$c \sim 330 \div 350$ м/с

Откуда берутся звуки в голосовом тракте?

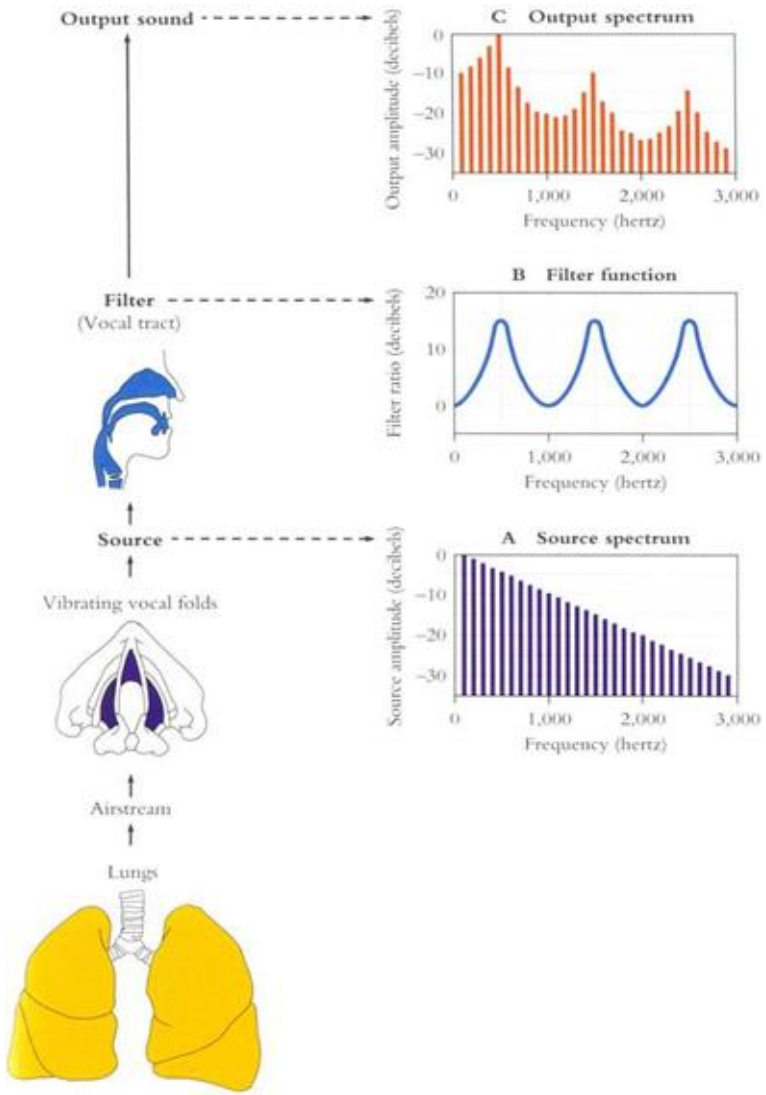

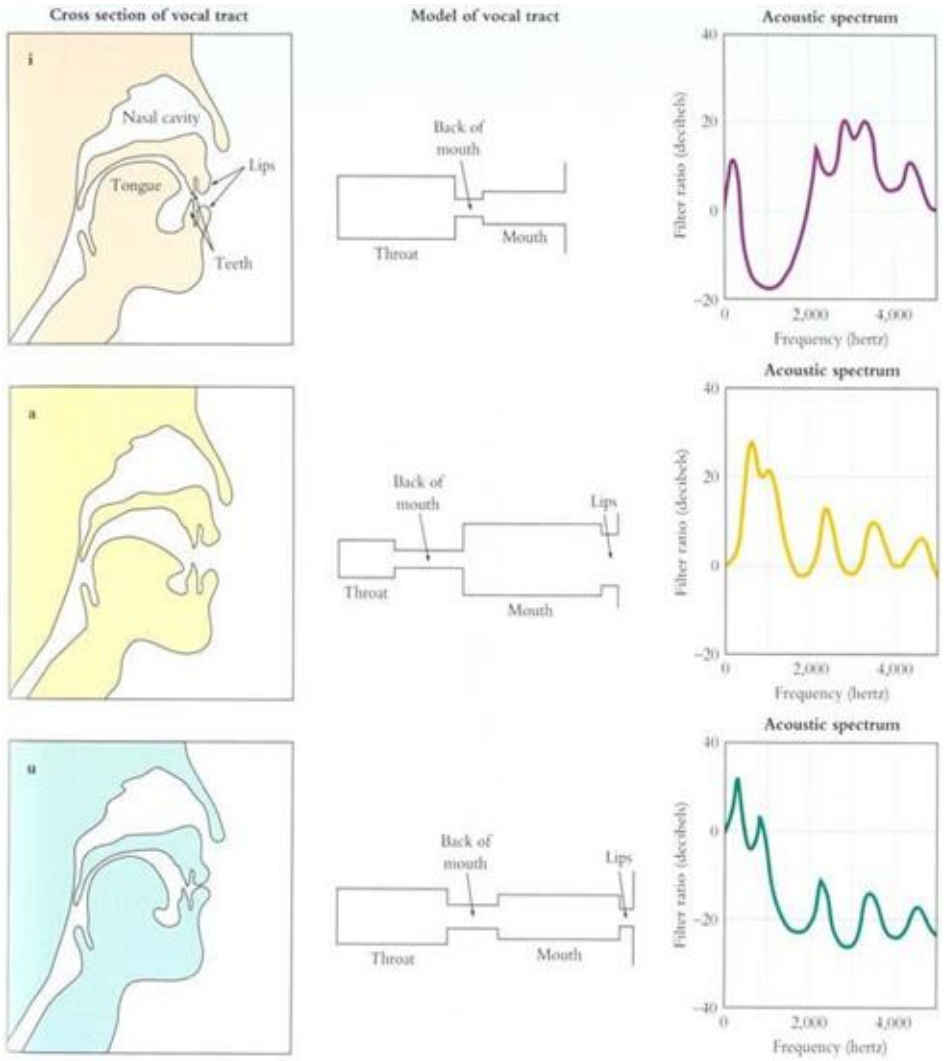

И еще немного про форманты

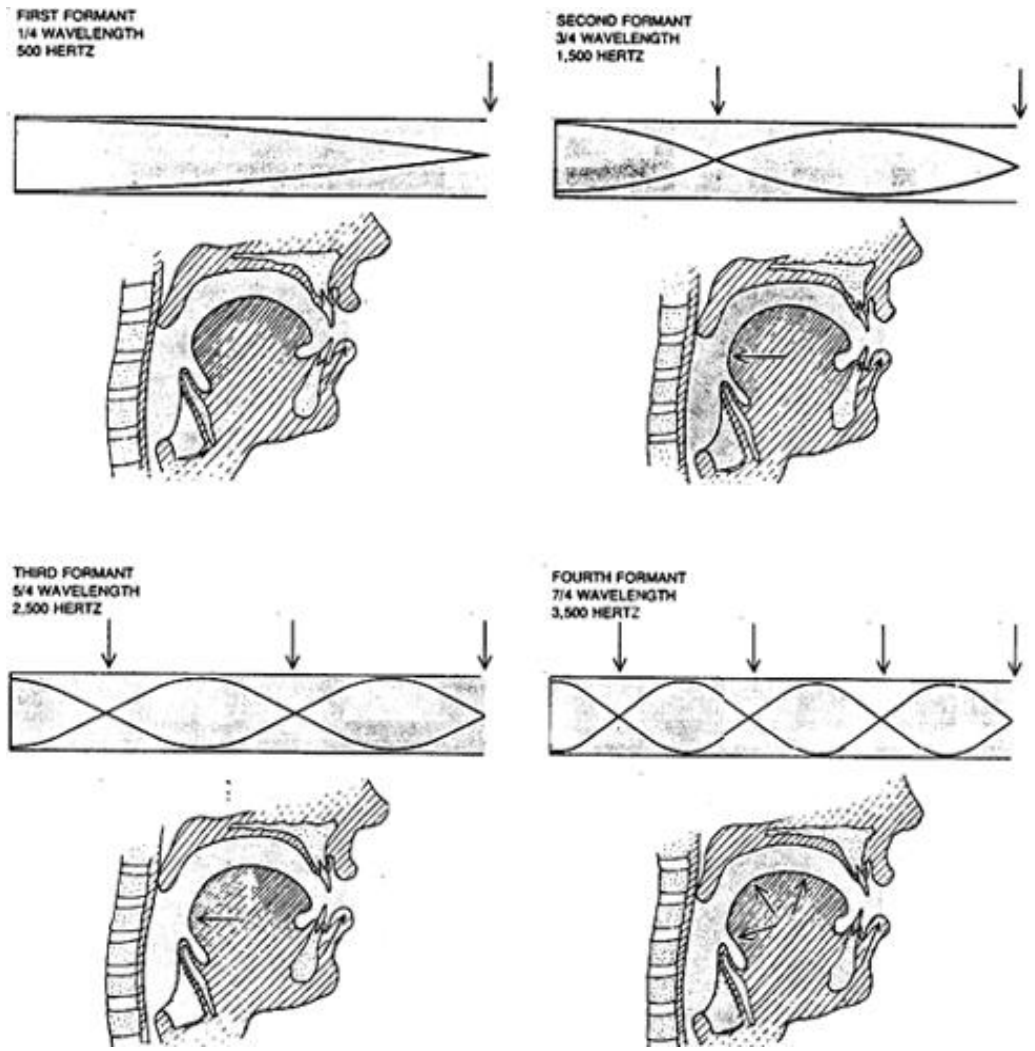

$F1 = c/\lambda 1 = c/(4L) = 35000/4*17,5 = 500Hz$

$F2 = c/\lambda 2 = c/(4/3L) = 3c/4L = 3*35000/4*17,5 = 1500Hz$

$F3 = c/\lambda 3 = c/(4/5L) = 5c/4L = 5*35000/4*17,5 = 2500Hz$

Мел-шкала

Люди воспринимают высоту звука в логарифмической шкале:

$200\ \text{Hz} \ll 300\ \text{Hz}$
$5000\ \text{Hz} \simeq 5100\ \text{Hz}$

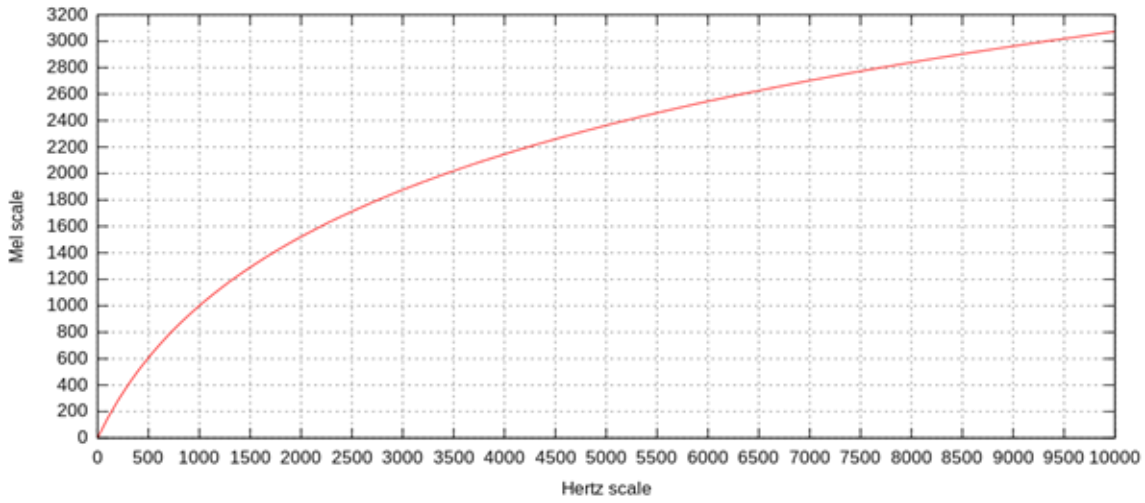

$$m = 2595 \log_{10}\left(1 + \frac{f}{700}\right) = 1127 \ln\left(1 + \frac{f}{700}\right)$$

The corresponding inverse expressions are:

$$f = 700\left(10^{\frac{m}{2595}} - 1\right) = 700\left(e^{\frac{m}{1127}} - 1\right)$$

Мел-спектрограмма

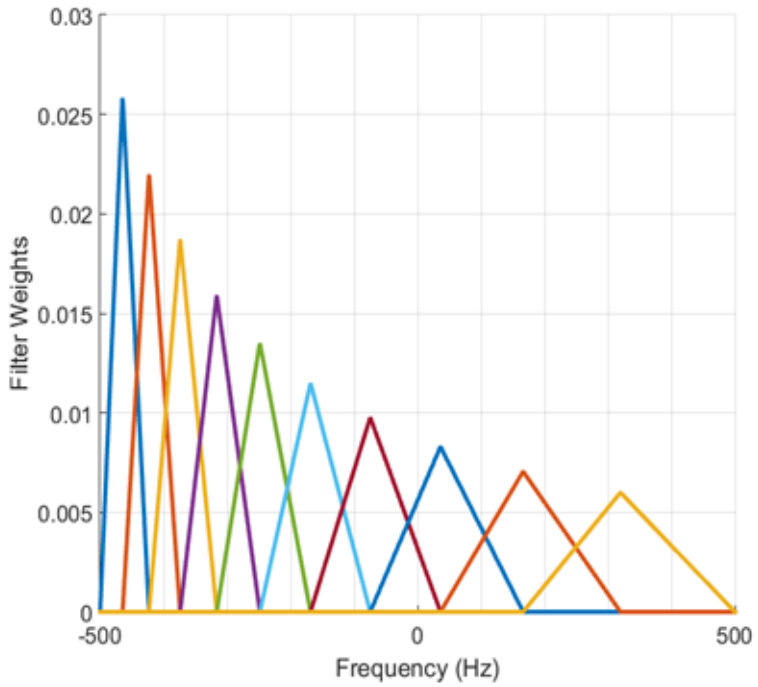

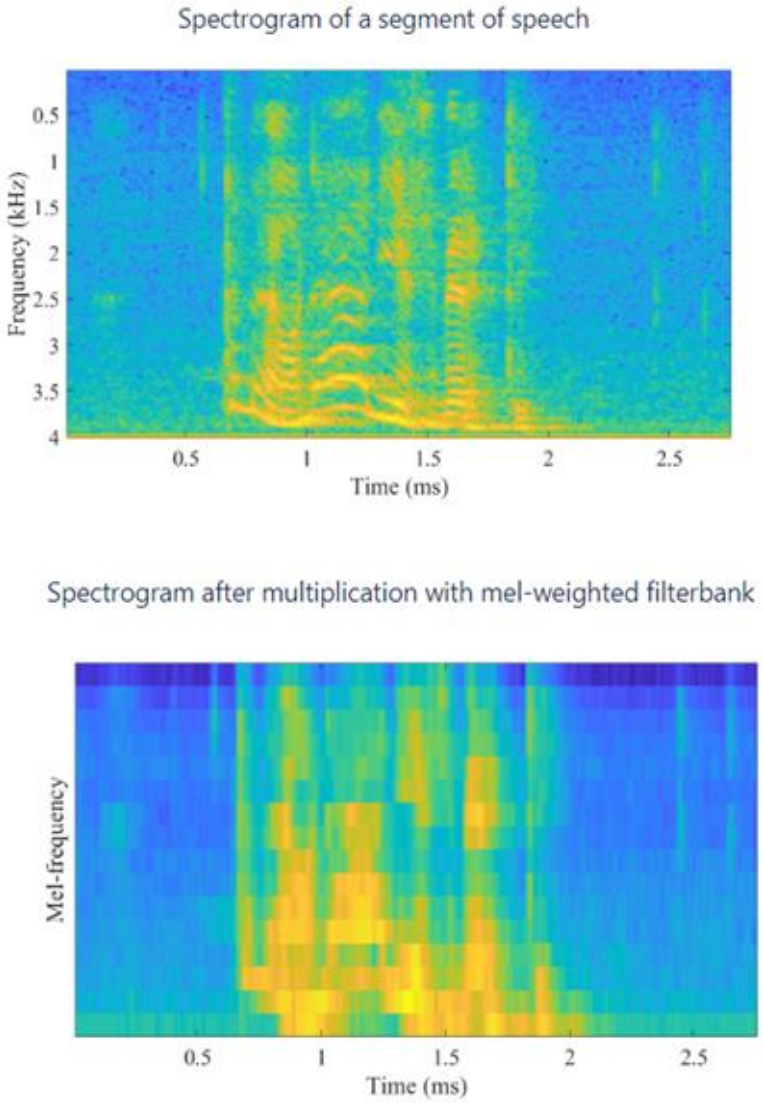

Фундаментальная частота F_0

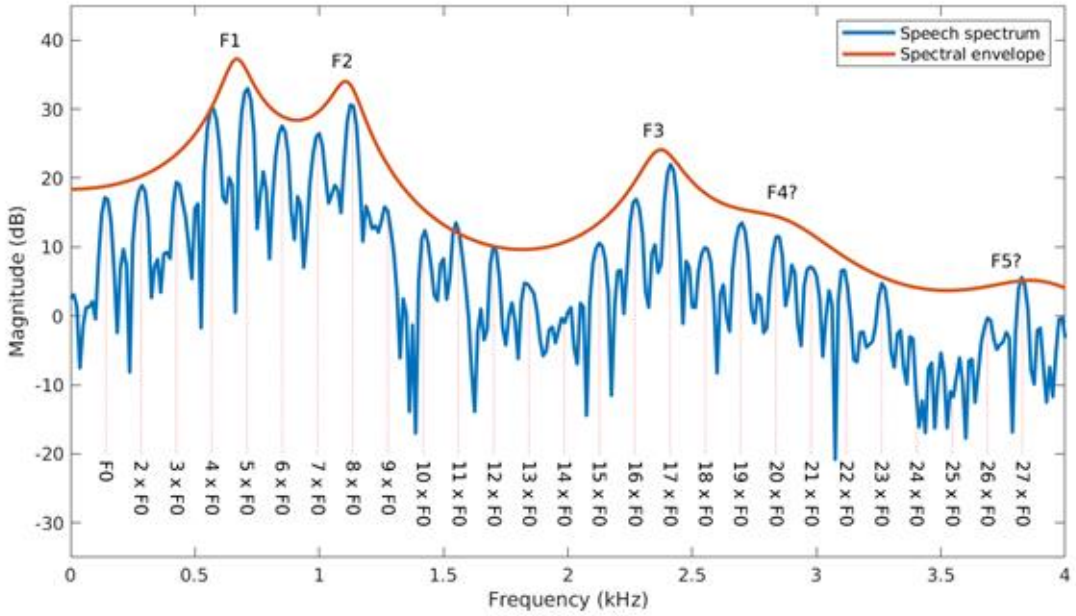

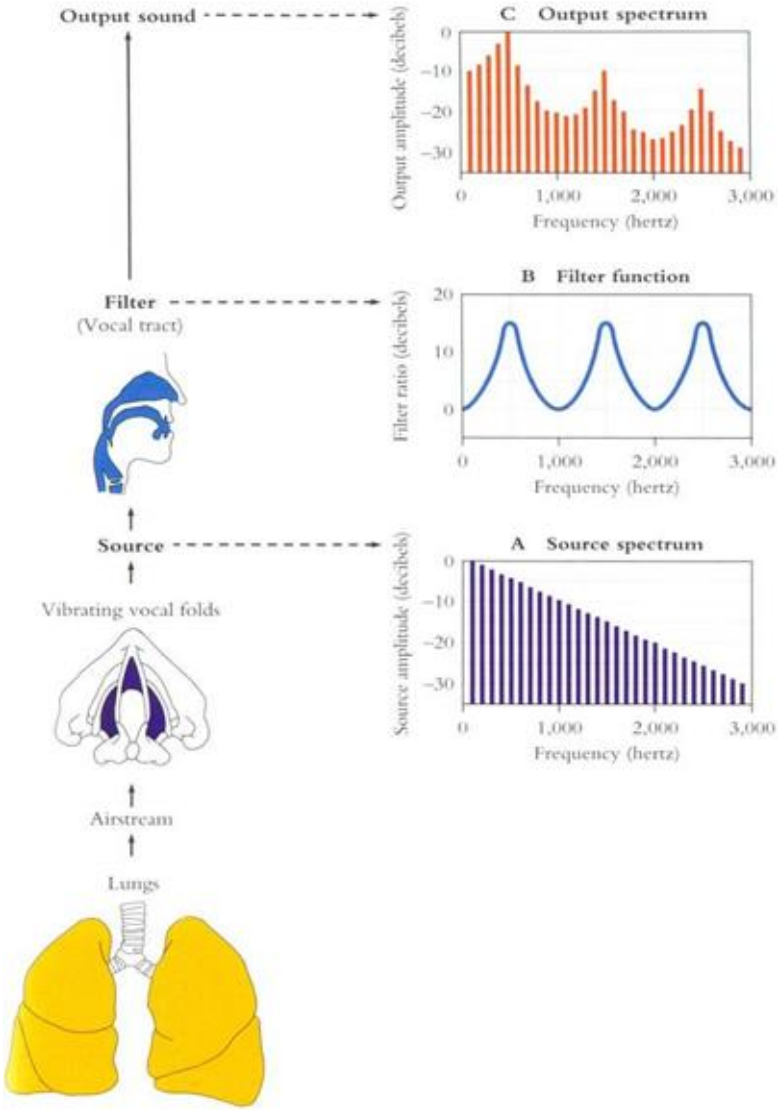

Высота голоса – ***перцептуальная*** величина
Фундаментальная частота – физическая

Диапазон $F_0 \sim 80 \div 450$ Гц

Кепстр

Спектр Фурье голоса имеет периодическую структуру

Можно применить дискретное косинусное преобразование **DCT** (Discrete Cosine Transform) и получить кепстр

Пику в кепстре будет соответствовать фундаментальная частота

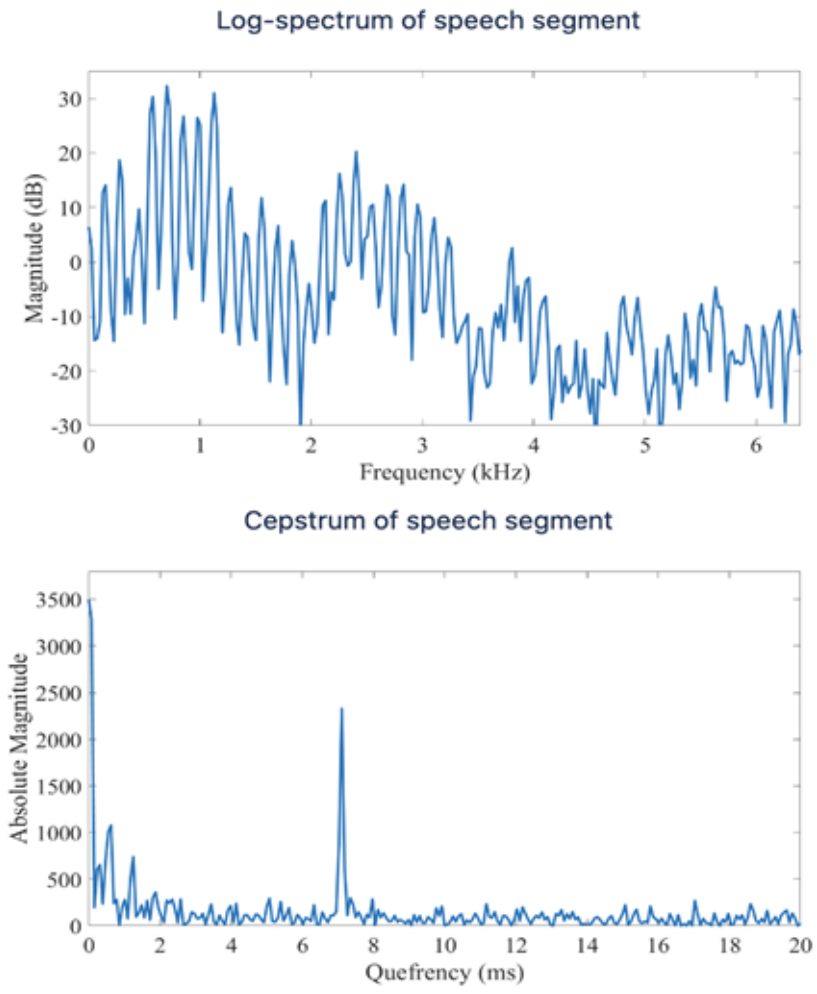

https://wiki.aalto.fi/display/ITSP/Cepstrum+and+MFCC

Мел-частотные кепстральные коэффициенты

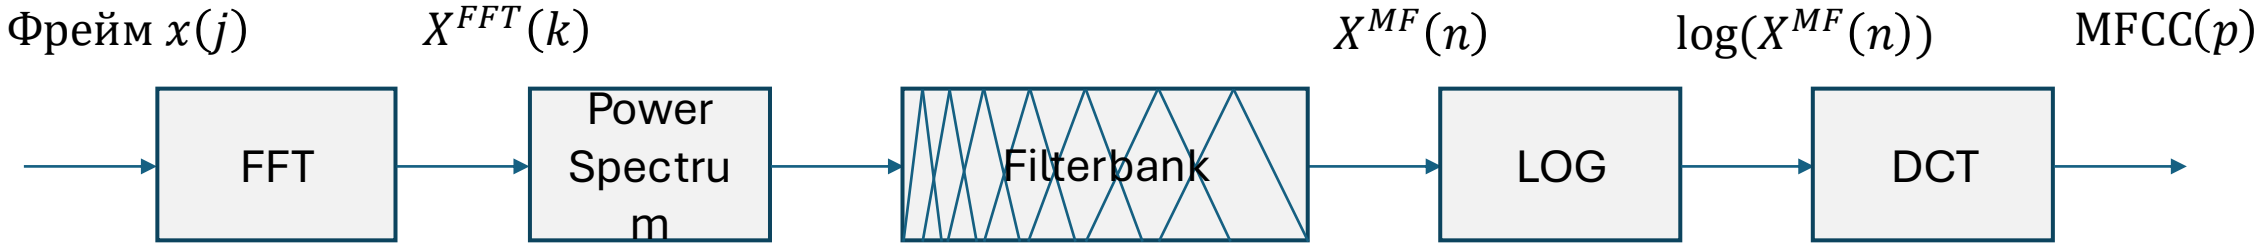

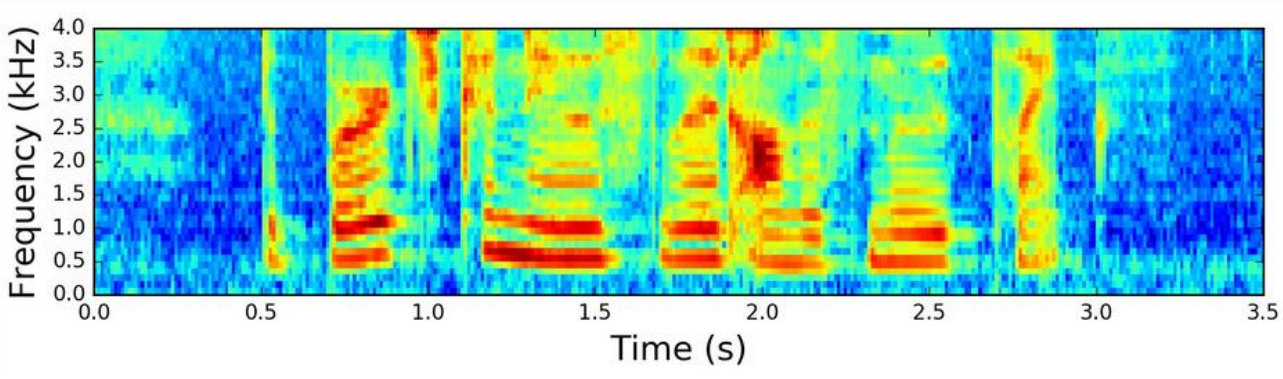

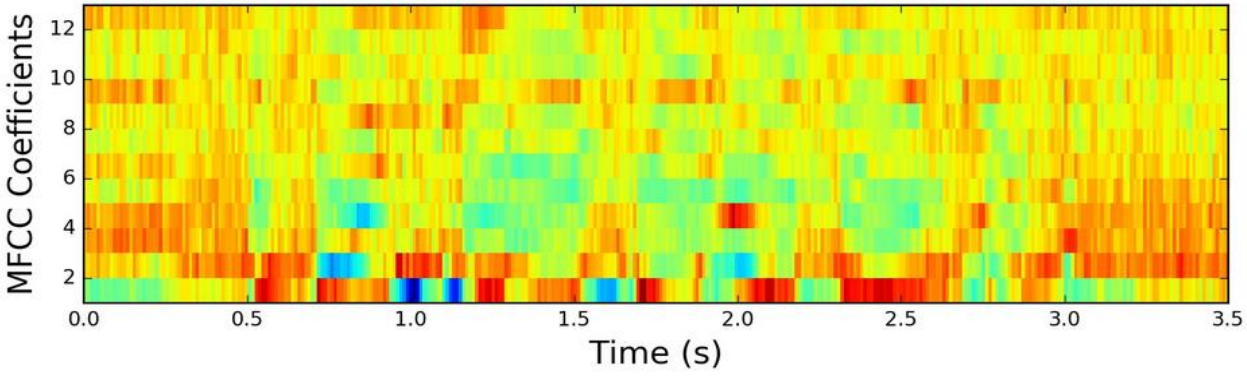

Основные задач обработки речи

- Текстозависимые (связанные с содержанием)
  - Распознавание речи (ASR)
  - Генерация речи (TTS)
  - Текстозависимая верификация/идентификация диктора
- Не зависящие от текста
  - Текстонезависимая верификация/идентификация диктора (ASV)
  - Классификация речевых сигналов (в том числе голосовых команд)
  - Улучшение качества речи (SE)
  - Разделение/выделение диктора (SS)
  - Обнаружение речи (VAD)